13주차

임상연구 코호트 추출 실전
연구 질문에서 Table 1까지

- 연구 질문 → 포함·제외 기준 → 쿼리
- Index date와 washout — '첫 진단'의 정의
- 단계별 코호트 조립 (WITH 구문)
- Table 1 자동 생성

> **이번 주 대표 질문**
>
> 2020년 이후 '첫' 뇌졸중 진단 환자를 뽑아보자

연구 질문을 데이터 언어로 번역하기

설계

연구 용어	뜻	SQL 대응물
포함 기준	어떤 환자를 코호트에 넣나	WHERE + JOIN (진단코드, 기간)
제외 기준	누구를 빼나	NOT EXISTS / NOT IN
Index date	각 환자의 '시계 0시' — 추적 시작일	MIN(visit_date) 등으로 정의
Washout	index date 이전 일정 기간(look-back) 질환 이력이 없어야 '신규'로 인정	HAVING MIN(…) ≥ 기준일 (간이형)
Table 1	코호트의 기저 특성 요약표	CASE × GROUP BY (6주차)

오늘의 연구 질문: **"2020년 1월 1일 이후 처음으로 뇌경색(I63)을 진단받은 성인 환자"**의 코호트를 만들고 기저 특성을 요약한다.

후보군 전체 훑기

임상 질문

1단계 — I63 진단 이력이 있는 환자와 첫 진단일

```sql
SELECT v.patient_id,
       MIN(v.visit_date) AS first_dx_date
FROM visit v
JOIN diagnosis d
  ON v.visit_id = d.visit_id
WHERE d.kcd_code LIKE 'I63%'
GROUP BY v.patient_id
ORDER BY first_dx_date;
```

patient_id	first_dx_date
P030	2019-09-29
P029	2019-11-03
P023	2020-04-21
P021	2020-12-13
P024	2021-03-05
P028	2021-05-25
P025	2023-01-31
P027	2023-03-28
P026	2024-08-05
P022	2025-03-19

총 10행

10명이 잡힙니다. 그런데 P029·P030의 첫 진단은 **2019년** — 이들은 2020년 이후 기준으로는 '신규 발생'이 아니라 '기존 환자'입니다. 여기서 washout이 등장합니다.

Index date 확정 — 간이 washout

대표 질문

임상 질문

2단계 — 신규 제한: 관찰된 '첫' 진단이 2020년 이후인 환자만

```sql
SELECT v.patient_id,
       MIN(v.visit_date) AS index_date
FROM visit v
JOIN diagnosis d
  ON v.visit_id = d.visit_id
WHERE d.kcd_code LIKE 'I63%'
GROUP BY v.patient_id
HAVING MIN(v.visit_date) >= '2020-01-01'
ORDER BY index_date;
```

patient_id	index_date
P023	2020-04-21
P021	2020-12-13
P024	2021-03-05
P028	2021-05-25
P025	2023-01-31
P027	2023-03-28
P026	2024-08-05
P022	2025-03-19

총 8행

P029·P030이 제외되어 8명이 남고, 첫 진단일이 **index date**가 됩니다. 엄밀한 washout은 index 이전 look-back 기간의 이력 부재 확인인데, 이 데이터는 관찰이 2019년부터라 이 조건이 **약 1년 look-back의 간이형**이 됩니다 — 정의서에 이 한계를 명시해야 합니다.

3단계 — WITH로 단계를 이름 붙여 조립하기

CTE

```sql
WITH stroke_cohort AS (          -- ① 신규 I63 코호트
  SELECT v.patient_id,
         MIN(v.visit_date) AS index_date
  FROM visit v
  JOIN diagnosis d ON v.visit_id = d.visit_id
  WHERE d.kcd_code LIKE 'I63%'
  GROUP BY v.patient_id
  HAVING MIN(v.visit_date) >= '2020-01-01'
)
SELECT c.patient_id, c.index_date,       -- ② 특성 붙이기
       p.sex,
       CAST(substr(c.index_date,1,4) AS INT)
         - CAST(substr(p.birth_date,1,4) AS INT)
         AS age_at_index
FROM stroke_cohort c
JOIN patient p ON p.patient_id = c.patient_id;
```

WITH(공통 테이블 표현식, CTE): 서브쿼리에 이름을 붙여 단계를 쌓는 문법. 정의서의 순서(포함→제외→특성)가 코드 구조에 그대로 보입니다. 나이는 연도 차이(연 나이) 근사 — 생일 미도래 시 1세 크게 계산될 수 있습니다.

동반질환 플래그 — EXISTS의 재등장

임상 질문

4단계 — 기저 변수: 고혈압(I10) 동반 여부 (index date 이전 이력만)

```
WITH stroke_cohort AS (
  SELECT v.patient_id,
         MIN(v.visit_date) AS index_date
  FROM visit v
  JOIN diagnosis d ON v.visit_id = d.visit_id
  WHERE d.kcd_code LIKE 'I63%'
  GROUP BY v.patient_id
  HAVING MIN(v.visit_date) >= '2020-01-01')
SELECT c.patient_id, c.index_date,
  CASE WHEN EXISTS (
    SELECT 1 FROM visit v2
    JOIN diagnosis d2
      ON d2.visit_id = v2.visit_id
    WHERE v2.patient_id = c.patient_id
      AND d2.kcd_code LIKE 'I10%'
      AND v2.visit_date <= c.index_date)
  THEN 1 ELSE 0 END AS htn_baseline
FROM stroke_cohort c;
```

patient_id	index_date	htn_baseline
P021	2020-12-13	1
P022	2025-03-19	1
P023	2020-04-21	0
P024	2021-03-05	0
P025	2023-01-31	0
P026	2024-08-05	1
P027	2023-03-28	1
P028	2021-05-25	1

총 8행

Table 1 생성

Table 1

임상 질문

5단계 — Table 1: 코호트 기저 특성 요약

```
WITH stroke_cohort AS (
  SELECT v.patient_id,
         MIN(v.visit_date) AS index_date
  FROM visit v
  JOIN diagnosis d ON d.visit_id = v.visit_id
  WHERE d.kcd_code LIKE 'I63%'
  GROUP BY v.patient_id
  HAVING MIN(v.visit_date) >= '2020-01-01')
SELECT p.sex AS 성별,
  COUNT(*) AS 명수,
  ROUND(AVG(CAST(substr(c.index_date,1,4) AS INT)
    - CAST(substr(p.birth_date,1,4) AS INT)), 1)
    AS 평균나이
FROM stroke_cohort c
JOIN patient p ON p.patient_id = c.patient_id
GROUP BY p.sex;
```

성별	명수	평균나이
F	4	58.3
M	4	55.3

총 2행

논문 Table 1의 뼈대가 완성됐습니다. 나머지 변수(동반질환율, 약물 노출률)도 같은 GROUP BY에 CASE 플래그를 추가하면 됩니다 — 6·12주차 기술의 총합.

보너스 — 자주 쓰는 코호트는 VIEW로 저장

VIEW

```sql
CREATE VIEW v_stroke_cohort AS
SELECT v.patient_id,
       MIN(v.visit_date) AS index_date
FROM visit v
JOIN diagnosis d ON d.visit_id = v.visit_id
WHERE d.kcd_code LIKE 'I63%'
GROUP BY v.patient_id
HAVING MIN(v.visit_date) >= '2020-01-01';

-- 이후로는 테이블처럼:
SELECT * FROM v_stroke_cohort;
```

VIEW는 **저장된 쿼리**(가상 테이블)입니다. 정의를 한 곳에 두면 공동연구자 모두가 같은 코호트 정의를 쓰게 됩니다 — '나만의 엑셀 사본' 문제(1주차)의 정반대.

조별 프로젝트 안내 — 코호트 정의서 · 추출 쿼리 · Table 1

프로젝트

제출물 (15주차 발표)

- ① **코호트 정의서** 1쪽 — 연구 질문, 포함·제외 기준, index date 정의
- ② **추출 쿼리** — WITH 단계 구조, 단계별 대상자 수 주석
- ③ **Table 1** — 성별·연령 + 조별 선택 변수 2개 이상

평가 기준

- 포함·제외 기준의 **임상적 타당성 (40%)**
- 기준 → 쿼리의 **정확한 번역 (30%)**
- Table 1 해석과 한계 논의 (20%)
- 발표 명료성 (10%)

attrition(단계별 대상자 수 감소 흐름): 포함 → washout → 제외 각 단계의 n을 쿼리 주석으로 남기면 심사와 재현이 쉬워집니다.

이번 주 용어 정리

용어

용어	뜻
포함 / 제외 기준	코호트에 넣을 조건 / 뺄 조건 — 정의서에 글로 먼저 쓴다
index date	환자별 추적 시작일(시계의 0시) — 나이·노출 계산의 기준 시점
washout	과거 일정 기간 이력이 없어야 '신규 발생'으로 인정하는 규칙
CTE (WITH 구문)	서브쿼리에 이름을 붙여 단계로 쌓는 문법 — Common Table Expression
VIEW	저장된 쿼리 — 테이블처럼 조회되는 가상 테이블, 정의 공유용
attrition	단계별 대상자 수 감소 흐름 — 각 단계의 n을 기록
Table 1	코호트의 기저 특성 요약표 — CASE 플래그 × GROUP BY로 생성

13주차 정리

- 코호트 추출 = **포함(JOIN·WHERE) → washout(HAVING MIN) → 제외(NOT EXISTS) → 특성(CASE·EXISTS)**
- Index date가 모든 시간 계산의 원점 — '언제 기준의 나이·노출인가'를 항상 명시
- **WITH(CTE)**로 정의서의 단계를 코드 구조로 — Methods와 1:1 대응
- 공유할 정의는 **VIEW**로 — 연구진 전원이 같은 코호트를 본다

과제 조별 프로젝트 착수 — 다음 주까지 연구 질문·포함 기준 초안

다음 주 이 결과를 믿어도 되나 — 의료데이터의 함정, 가명처리와 IRB, RDB 밖의 데이터