14주차

이 결과를 믿어도 되나?
의료데이터의 함정과 책임

- 단위 불일치 · 측정시각 · 코드 버전 — 3대 함정
- 결측이 유병률을 왜곡하는 방식
- 개인정보보호법 · 가명처리 · IRB
- 영상·파형·판독문 — RDB 밖의 데이터

이번 주 대표 질문

내가 뽑은 이 숫자를 논문에 실어도 되는가?

이 7.8은 저혈당인가?

함정 1

임상 질문

함정 ① 단위 불일치 — 우리 혈당 데이터에 숨어 있던 것

```
SELECT lab_id, test_name,
       result_value, unit
FROM lab
WHERE test_name = 'Glucose'
ORDER BY result_value
LIMIT 5;
```

lab_id	test_name	result_value	unit
L0092	Glucose	7.8	mmol/L
L0089	Glucose	82	mg/dL
L0086	Glucose	101	mg/dL
L0083	Glucose	108	mg/dL
L0027	Glucose	112	mg/dL

총 5행

7.8 mmol/L = 약 140 mg/dL — **단위가 다르면 같은 숫자가 정반대 의미**가 됩니다. 단위 확인 없이 AVG를 돌리면 평균이 통째로 왜곡됩니다. 실무 수칙: 수치 분석 전 `GROUP BY unit`으로 단위 분포부터.

분석 전 30초 감사(audit) 습관

임상 질문

함정 ① 대응 — 단위 감사 쿼리

```sql
SELECT test_name, unit,
       COUNT(*) AS 건수,
       MIN(result_value) AS 최소,
       MAX(result_value) AS 최대
FROM lab
GROUP BY test_name, unit
ORDER BY test_name;
```

test_name	unit	건수	최소	최대
CRP	mg/L	6	48.3	169
Creatinine	mg/dL	4	1.97	2.2
Glucose	mg/dL	27	82	218
Glucose	mmol/L	1	7.8	7.8
HbA1c	%	17	6.7	9.5
Hemoglobin	g/dL	10	9.8	15.7
LDL	mg/dL	28	115	184

총 7행

Glucose에 단위가 **두 종류**인 것이 즉시 드러납니다. 새 데이터셋을 받으면 ①단위 분포 ②MIN/MAX ③결측 수 — 3종 감사부터 실행합니다.

함정 ② 시각의 여러 얼굴 — 어느 시간이 '진짜'인가

같은 검사 하나에도

- **처방 시각** — 의사가 오더 낸 때
- **채혈 시각** (collected_at) — 검체가 몸에서 나온 때
- **결과보고 시각** — 수치가 확정된 때
- 기록 시각 — 시스템에 입력된 때

왜 중요한가

- 공복혈당 연구인데 **오후 채혈**이 섞이면? — 우리 데이터의 함정 검사(14시 채혈)처럼
- '입원 후 48시간 내 항생제'는 **어느 시각 기준**인가에 따라 결과가 달라진다
- 논문 Methods에 시각 정의를 **명시**해야 재현 가능

> 임상적으로 의미 있는 시각은 대부분 **검체 채취·측정 시각**입니다 — 기록 시각과 몇 시간씩 어긋날 수 있습니다.

함정 ③ 코드는 살아 움직인다

- **코드 버전 변경**

  KCD는 주기적으로 개정 — 같은 질환의 코드가 시기별로 다를 수 있다

- **코딩 관행의 변화**

  특정 진단의 '유행'은 질병 증가가 아니라 수가·지침 변화일 수 있다

- **주진단 vs 부진단**

  is_primary를 무시하고 세면 '입원 사유'와 '동반 상병'이 뒤섞인다

- **매핑 테이블의 필요**

  다기관 연구는 코드 → 표준 개념(OMOP) 매핑이 절반의 일

> 진단코드 기반 연구의 고전적 경고: **"코드가 늘어난 것인가, 병이 늘어난 것인가?"**

분모가 다르면 결론이 다르다

임상 질문

결측의 왜곡 — '검사받은 사람만'의 평균이라는 것

```
SELECT
  (SELECT COUNT(DISTINCT v.patient_id)
   FROM visit v JOIN diagnosis d
     ON d.visit_id = v.visit_id
   WHERE d.kcd_code LIKE 'E11%') AS 당뇨환자수,
  (SELECT COUNT(DISTINCT v.patient_id)
   FROM visit v JOIN lab l
     ON l.visit_id = v.visit_id
   WHERE l.test_name = 'HbA1c'
     AND v.patient_id IN (
       SELECT v2.patient_id
       FROM visit v2 JOIN diagnosis d2
         ON d2.visit_id = v2.visit_id
       WHERE d2.kcd_code LIKE 'E11%'))
    AS 당뇨환자중검사자수;
```

당뇨환자수	당뇨환자중검사자수
8	6

총 1행

개인정보보호 — 연구자가 알아야 할 최소한

법·윤리

구분	내용	예
익명정보	누구인지 복원 불가능 — 개보법 적용 제외	통계표, 완전 집계값
가명정보	추가 정보 없이는 특정 불가하게 처리 과학적 연구 등 목적에 한해 활용 근거 마련(개보법 §28-2 — 요건·예외는 기관 지침 확인)	P001처럼 ID 치환, 생년월일 → 연령대
민감정보	건강정보는 민감정보 — 원칙적 처리 제한, 별도 보호	진단명, 검사결과
IRB	인간대상연구 심의 — 후향적 DB 연구 포함, 심의면제 여부의 판단도 IRB 몫	연구계획서 사전 제출

미니 EMR에 이름·주민번호가 **처음부터 없었던** 이유 — 이 데이터셋 자체가 가명처리의 모형입니다. 표의 내용은 개인정보보호법·생명윤리법의 **2026-07 기준 교육용 요약**이며, 실제 연구 전에는 소속기관 IRB·개인정보보호 담당자와 상의하세요.

접근 권한 — 최소 권한의 원칙 (DCL 한 장)

- **GRANT / REVOKE**

  `GRANT SELECT ON lab TO 연구자;` — 필요한 테이블에, 필요한 동작만

- **역할 기반(RBAC)**

  '연구자' 역할에 조회 권한만 — 개인이 아닌 역할에 권한을 부여

- **감사 추적**

  누가 언제 무엇을 조회했는지 로그 — 8주차 감사로그의 조회 버전

- **연구자의 현실**

  연구자용 CDW 계정은 대부분 SELECT 전용 — 최소 권한 원칙의 적용 결과

> 권한 관리 실패는 해킹 없이도 **유출 사고**로 이어집니다 — 최소 권한은 그 첫 방어선입니다.

비정형 텍스트의 한계

비정형

임상 질문

RDB 밖의 데이터 — 판독문은 왜 '검색'이 어려운가

```
SELECT img_id, modality, body_part,
       report
FROM imaging
WHERE report LIKE '%경색%';
```

img_id	modality	body_part	report
IMG001	MRI	뇌	좌측 중대뇌동맥 영역에 급성 뇌경색 소견. 출혈성 변화는 관찰되지 않음.
IMG003	MRI	뇌	좌측 중대뇌동맥 영역에 급성 뇌경색 소견. 출혈성 변화는 관찰되지 않음.
IMG004	MRI	뇌	좌측 중대뇌동맥 영역에 급성 뇌경색 소견. 출혈성 변화는 관찰되지 않음.
IMG005	MRI	뇌	좌측 중대뇌동맥 영역에 급성 뇌경색 소견. 출혈성 변화는 관찰되지 않음.

… 총 8행 중 4행 표시

LIKE 검색은 되지만 — "급성 경색 **소견 없음**"도 '%경색%'에 걸립니다. 부정 표현, 동의어, 오타… 텍스트의 의미는 LIKE로 잡히지 않습니다. 그래서 판독문 연구는 NLP(자연어처리)의 영역으로 넘어갑니다.

영상 · 파형 · 텍스트 — RDB 밖의 저장소

생태계

RDB에 안 넣는 이유

- MRI 한 검사 수백 MB — RDB 내부 저장(BLOB)도 가능하지만 운영·백업·전송 부담이 커진다
- 행·열 구조가 무의미한 픽셀·파형 데이터
- 그래서 **RDB에는 메타데이터**(우리 imaging 테이블), 실제 파일은 PACS·전용 저장소에 두는 구조가 일반적

AI 학습 데이터셋의 구조

- 영상 파일 (PACS) + **레이블** (RDB에서 추출한 진단·판독)
- "폐렴 X-ray 분류"의 **후보 레이블**은 imaging×diagnosis 조합에서 출발 — 시점 정렬·레이블 정의·품질관리는 별도 작업
- SQL은 이 중 **코호트·레이블 후보 추출**에 쓰이는 도구다

> NoSQL·데이터레이크는 이 비정형 세계의 저장 기술입니다 — 관계형이 끝이 아니라, 관계형이 **중심축**인 생태계.

최종 점검 리스트 — "이 결과를 믿어도 되나?"

체크리스트

- **단위** — 같은 검사에 단위가 하나인가? (GROUP BY unit)
- **분모** — 이 평균·비율은 **누구의** 평균·비율인가? (결측·LEFT JOIN)
- **시각** — 어느 시각 기준인가? (채혈 vs 기록)
- **단위 수준** — 내원 수를 환자 수로 착각하지 않았나? (COUNT DISTINCT)
- **코드** — 정의한 코드 패턴이 임상적으로 타당한가? (주진단 여부 포함)
- **권한·윤리** — 이 데이터를 이 목적으로 써도 되는가? (가명처리·IRB)

> 프로젝트 발표(15주차)에서 이 6개 항목으로 서로의 결과를 교차 검증합니다 — 각 항목의 점검 쿼리는 이번 주 노트북에 있습니다.

이번 주 용어 정리

용어	뜻
가명정보	추가 정보 없이는 누구인지 특정 불가하게 처리한 정보 — 연구 목적 활용 근거(개보법 §28-2)
익명정보	복원 자체가 불가능한 정보 — 개인정보보호법 적용 제외
민감정보	건강정보 등 법이 특별히 보호하는 정보 — 원칙적 처리 제한
IRB	기관생명윤리위원회 — 인간대상연구(후향적 DB 연구 포함) 심의 기구
RBAC	역할 기반 접근 제어 — 개인이 아닌 역할(연구자 등)에 권한 부여
감사 쿼리(audit query)	분석 전 단위·범위·결측을 점검하는 사전 검증 쿼리
NLP (자연어처리)	판독문 등 텍스트의 의미를 다루는 기술 — LIKE 검색의 한계 너머
DCL (Data Control Language)	권한을 다루는 SQL — GRANT(부여)·REVOKE(회수)
NoSQL	테이블·SQL 구조를 따르지 않는 DB 총칭 — 문서형·키값형 등, 비정형 대용량에 강점
데이터레이크(data lake)	원시 데이터를 형식 그대로 쌓아두는 대용량 저장소 — 영상·로그·텍스트까지

14주차 정리

- 3대 함정: **단위 · 시각 · 코드** — 분석 전 감사 쿼리(단위 분포·MIN/MAX·결측)가 첫 단계
- 평균·비율 앞에서 항상: **"분모가 누구인가?"**
- 건강정보는 민감정보 — **가명처리 + IRB + 최소 권한**이 연구의 입장권
- 영상·텍스트는 RDB 밖에 있지만, **코호트·레이블 후보 추출에는 SQL**이 쓰인다

과제 프로젝트 최종 점검 — 위 체크리스트 6항목을 자기 결과에 적용해 볼 것

다음 주 15주차 조별 프로젝트 발표 — 코호트 정의서 · 추출 쿼리 · Table 1